

Real Estate Rental Trends : Clustering for Insights

שם הקורס:

נושאים מתקדמים בלמידת מכונה

שם המרצה:

ד"ר חגית חן

שמות חברי הצוות:

סהר סוקוליק – 205937287

עמית גידו - 315754606

תוכן עניינים:

3.....	תקציר
4.....	מבוא
5-6.....	מסד נתונים ותכונות
7-8.....	מתודולוגיה
8-12.....	ניסויים/תוצאות/דיון
13-14.....	מסקנות ועבודה עתידית
14.....	חלוקת עבודת הצוות

תקציר:

כחלק מקורס "נושאים מתקדמים בלמידת מכונה" ביצענו פרויקט אשר משתמש בטכניקות מתקדמות של למידת מכונה ובעיקר Clustering כדי לנתח ולהבין את עולם השכרת הנכסים בעיר תל אביב-יפו. באמצעות כריית נתונים ועיבוד מקדים של כ-275,000 רישומים מהעשור האחרון, התחלנו בניתוח מקיף כדי לפענח את הקשרים המורכבים בין מאפייני הנכס, מיקומים גיאוגרפיים, ממדים זמניים ומחירי שכירות.

ביצענו את הפרויקט תוך שימוש באלגוריתמים של למידת מכונה, בין היתר השתמשנו באלגוריתמים כמו K-Means, Hierarchical Clustering ו-DBSCAN, לצד XGBoost לניתוח רגרסיה וחשיבות תכונות. מחקר זה לא רק מזהה את הדפוסים המוכרים בתוך הנתונים אלא גם חושף קורלציות/קשרים בלתי צפויים המשפיעים על עלויות השכירות. כמו כן, יצרנו משתנים מרוכבים שבעזרתם ניסינו לזהות מגמות בנתונים שלנו. המתודולוגיה שלנו מדגישה את ההשפעה המשמעותית של מאפיינים שונים עבור נכסים ספציפיים ואת השפעת המיקום על אסטרטגיות תמחור שכירות, ובכך מציעה פרספקטיבה המנסה להסביר את התנהגויות השוק.

התובנות המרכזיות עשויות לספק גישה למדיניות דיור יעילה יותר ולהקל על תהליכי קבלת החלטות בהסתמך על ניתוח נתונים בתחום הנדל"ן. פרויקט זה מדגיש את החשיבות של מינוף ושימוש בלמידת מכונה כדי לשפר את ההבנה של דינמיקה מורכבת בשוק ולתרום לפיתוח פתרונות דיור כוללים יותר בערים נוספות בעולם אשר דומות באופיין לעיר תל אביב-יפו.

[קישור ל-GITHUB של הפרויקט](#)

מבוא:

מציאת דיור 'בר-השגה' בערים גדולות ומטרופולינים צפופים הפכה להיות משימה כמעט בלתי אפשרית בשנים האחרונות בקרב מרבית האוכלוסיות ובפרט בקרב האוכלוסיות הצעירות. בעבודתנו, בחרנו להתמקד בעיר גדולה המהווה מטרופולין ראשי - העיר תל אביב-יפו. שוק השכירות מאופיין בביקוש עצום, היצע מוגבל וחוסר שקיפות משמעותי בקביעת המחירים. כצעירים הנאבקים למצוא נכס להשכרה, אנו חשים חוסר הבנה עמוק באשר לגורמים האמיתיים המשפיעים על עלויות השכירות הגבוהות. אנו רואים בנושא זה בעיה משמעותית וחשובה אשר מחייבת חקר מעמיק. לכן, בחרנו להתמקד בה במסגרת פרויקט הגמר. חשיבות הנושא טמונה בהשלכות הרחבות שיש לו על איכות החיים והיציבות הכלכלית של אוכלוסיות שונות ובפרט האוכלוסייה הצעירה, ובפוטנציאל שלו להוביל לתובנות ברות יישום בקביעת מדיניות דיור ציבורית אפקטיבית יותר.

המטרה המרכזית של פרויקט זה היא להשתמש בשיטות מתקדמות של למידת מכונה על מסד נתונים גדול של מודעות שכירות, במטרה לחשוף קשרים ודפוסים חדשים ומפתיעים בין מאפיינים שונים של הדירות, מידת הזמן והמיקום הגיאוגרפי לבין מחירי השכירות. הפרויקט ישתמש באלגוריתמים מורכבים של DBSCAN, Means-K Clustering ו-Hierarchical Clustering. בנוסף, שימוש במודלים לינאריים ולא-לינאריים וטכניקות לבחירה וצמצום פיצ'רים, במטרה לאתר תבניות חריגות, קבוצות פיצ'רים לא צפויות שמשפיעות על המחיר.

הפרויקט צפוי לתרום להתפתחותם של אלגוריתמים חדשניים המותאמים במיוחד לאתגרי ניתוח ומציאת תבניות בנתוני נדל"ן עירוניים, בעלי ערך רב לתחומי ידע נוספים ואזורים אחרים בעולם. הצלחתנו עשויה לקדם שימוש נרחב של השיטות האלו לטובת הבנה טובה יותר לקביעת מחירים, עשוי להוביל לנקיטת מדיניות אפקטיבית יותר וקבלת החלטות אשר מבוססות על נתונים בשוקי נדל"ן בהתאם למדינות השונות.

[קישור ל-Github של הפרויקט](#)

סעיף 3 – מסד נתונים ותכונות -הסבר על משיכת הדאטה והפיצ'רים:

פיתחנו ממשק תכנות אוטומטי באמצעות הספריות Requests, BeautifulSoup שתפקידו לכתוב את מלוא המידע הרלוונטי מאתר אינטרנט שמפרסם מודעות להשכרת דירות בעיר תל אביב-יפו.

האלגוריתם פועל באופן הבא:

1. חיפשו חוקיות בשורת ה-URL בין דפי המודעות השונים.
2. בכל דף מודעות בודד, חיפשו את הלינקים (ID) שמובילים למודעה בודדת.
3. בכל דף מודעות בודד, חיפשו את ה-CLASSים שמכילים את המידע שרצינו לכתוב עבור נכס בודד להשכרה.
4. בנינו Scraper שיודע לכל נכס/מודעה בודדת למצוא ולייצא/לכתוב את השדות שנחוצים לנו.
5. בעזרת ספריית BeautifulSoup ובקשות Requests לכל מודעה בודדת ביצענו כריית נתונים.
6. את כריית הנתונים חילקנו לאצוות (Batch). בגודל של 50 דפים בכל אצווה ובכל דף יש 48 מודעות שונות של נכסים להשכרה. ביצענו זאת לטובת צמצום קריסות של האלגוריתם והגברת הביצועים.
7. שמירת הדאטה התבצעה לפי אצווה – כל אצווה מייצגת קובץ אקסל אשר מכיל 50 דפים*48 מודעות שהם 2400 שורות של נתונים.
8. לבסוף, ביצענו איחוד של הקבצים לקובץ שלם שמכיל כ-275,000 מודעות להשכרה שפורסמו לאורך העשור האחרון בעיר תל אביב-יפו.

עיבוד מוקדם מקיף והתאמת מרחב התכונות:

1. טיפול בערכים כפולים - בדיקת כפילויות, לא היו ערכים כפולים.
2. סינון חריגים קיצוניים - ביצענו ניתוח סטטיסטי מקיף לזיהוי ערכי קיצון במחירים, שטחים וכיו"ב. תוך שימוש בויזואליזציות תומכות, סיננו ערכים אשר עלולים להיות תוצאה של טעויות ולהטות את הממצאים.
3. עמודה מסוג תאריך העברנו לעמודה מסוג Date.time לצורך עבודה עם פונקצייה של זמן.
4. טיפול בערכים חסרים - בדקנו האם קיימים ערכים חסרים בדאטה ועקב כמות נתונים מספקת אמוד, החלטנו להוריד את כל הערכים החסרים באופן גורף כשיטה לטיפול בערכים החסרים ומניעת הטיית הממצאים (כ-40,000 שורות נתונים נותרו).
5. השמטת תכונות חסרות משמעות: הבנו שחלק מהתכונות הקיימות במסד לא צפויות להיות רלוונטיות להסבר השונות במחירי השכירות. לדוגמה - מספרי טלפון, שמות משכירים, שם העיר (שהינה תל אביב-יפו בכל המקרים), ולינק למודעה.

התאמת מרחב התכונות:


- בדיקת קורלציות בין פיצ'רים - בנינו heatmap לבדיקת קורלציות בין כל זוג תכונות והשמטנו תכונות עם קורלציה גבוהה מ-0.7.
- קידוד וקטורי לתכונות בינאריות טקסטואליות - תכונות כמו "מרפסת"/"משופצת/מחסן/מעלית/חנייה" ועוד קודדו תכונות בינאריות 0/1 בתהליך כריית הנתונים.

יצירת תכונות מורכבות על סמך קורלציות:

- לאחר בחינת מקדמי המתאם בין התכונות, בחרנו את התכונות הרלוונטיות לתהליך Clustering. במקום להשאיר כל תכונה כשלעצמה, יצרנו מניפולציה על הנתונים ובנינו משתנים חדשים כמו – 'מחיר למ"ר', 'גודל ממוצע לחדר' שבעזרתם יצרנו משתנים מרוכבים כמו – 'מחיר למ"ר X גודל הנכס במ"ר' ו- 'מחיר למ"ר X מספר חדרים'. המטרה הייתה לתת ייצוג שונה לנכסים מהמשתנים האינטואיטיביים ושידועים מראש.
- מעמודת ה'Date post' יצרנו עמודה חדשה בשם 'Season' שלוקחת את החודש שבו פורסמה המודעה ומסווגת אותו לפי עונות השנה (Winter, Spring, Summer, Autumn) בהתאמה $[[12,1,2],[3,4,5],[6,7,8],[9,10,11]]$.

הרציונל מאחורי ביצוע העיבוד המקדים של הדאטה והפצ'רים ובניית משתנים מורכבים הוא:

- הנתונים ברובם נתונים בידיים, כך שביצוע Clustering עליהם כמעט ולא אפשרי ונאלצנו ליצור ולחשוב על משתנים מורכבים רציפים שבעזרתם נוכל ליצור Clustering.
- להבטיח אמינות וטוהר הנתונים באמצעות הסרה של ערכים חסרים/מוטעים.
- למנוע הטיות אפשריות הנגרמות משגיאות מדידה או ערכי קיצון חריגים.
- לפתור בעיות סטטיסטיות אפשריות הקשורות למולטיקוליריות.
- לאפשר ייצוג יעיל של תכונות בינאריות עבור המודלים.
- להעשיר את מרחב התכונות במידע חדש רלוונטי תוך שימוש בתכונות מורכבות.



קישור ל-Github של הפרויקט

סעיף 4 - מתודולוגיה, אלגוריתמים וטכניקות שהופעלו ומה הנימוקים והחשיבה האנליטית שהובילו אותנו במהלך הפרויקט:

לאחר הכנת מסד הנתונים וטיובו, נקטנו בגישה אשר שילבה מספר שיטות למידת מכונה שונות כדי לנתח את הנתונים ולחשוף קשרים מורכבים בין מאפייני הדירות, ממדי הזמן לבין מחירי השכירות:

1. קלסטרינג באמצעות K-Means ושיטת המרפקים (Elbow Method):

בשלב הראשון, החלטנו להפעיל את אלגוריתם K-Means Clustering על הנתונים. מטרת האלגוריתם היא לחלק דוגמאות לקבוצות (קלסטרים) הומוגניות על בסיס הדמיון בין מאפייניהן. שיטת המרפקים היא טכניקה לקביעת מספר האשכולות (K) האופטימלי על ידי בחינת הצירוף של "Intra-cluster distances" וה-"Inter-cluster distances" של הנתונים. בחרנו להשתמש בשיטות אלה כדי לאפשר זיהוי של דפוסים וקבוצות טבעיות בנתונים, מה שיכול לסייע בבניית ויזואליזציות משמעותיות ורלוונטיות המחלקות את הנתונים בצורה שאינה אינטואיטיבית בהכרח. כמו כן, ערכנו ניסיונות עם מספר ערכי k שונים והשתמשנו בשיטת "המרפק" לבחירת k אופטימלי.

2. XGBoost:

מאחר ששיטות קלאסיות כמו רגרסיה לינארית לא תמיד מצליחות להבין דפוסים, תבניות או בנייה מורכבת בנתונים, בחרנו להשתמש ב-XGBoost (Extreme Gradient Boosting). XGBoost הוא אלגוריתם למידת מכונה מבוסס עצי החלטה, רלוונטי לשימוש בבעיות מסוג רגרסיה וסיווג בעקבות יעילות ודיוק גבוהים. כתוצאה מתכונות אלו, הוא מאפשר לזהות את חשיבות הפיצ'רים השונים ולדרג אותם על פי תרומתם למודל, מה שהופך אותו לכלי מתאים לבדיקת חשיבות הפיצ'רים לצורך המשך בניית ויזואליזציות. כלומר, אלגוריתם זה יכול לסייע בהבנת המשקל של כל פיצ'ר על מחיר הנכס ביחס לגורם הזמן.

3. DBSCAN:

DBSCAN הוא אלגוריתם Clustering נוסף המבוסס על צפיפות הנתונים. הוא מזהה אשכולות בעלי צורות לא רגולריות ומסוגל להתמודד עם רעשים ונקודות חריגות בצורה טובה. בחירת DBSCAN מבוססת על היכולת שלו לזהות דפוסים מורכבים בנתונים, מה שעשוי להיות רלוונטי לבניית ויזואליזציות מורכבות ומגוונות. יתרונו העיקרי של DBSCAN הוא היכולת שלו לגלות דפוסים מורכבים ולא לינאריים בקרב הנכסים, אשר עשויים להיות קשורים למאפיינים ייחודיים כמו מיקום גיאוגרפי וסוג הנכס.

4. Hierarchical Clustering <- Dendrogram:

ייצוג גרפי של אשכול היררכי, המציג את הקשרים והמרחקים בין הנתונים השונים. טכניקה זו נבחרה כדי לספק תובנות נוספות על המבנה והקשרים בין הנתונים, מה שעשוי לסייע בהבנה טובה יותר של הנתונים ובבניית ויזואליזציות המשקפות את המבנה הזה. בעץ ההיררכי, כל נקודה (=נכס) מיוצגת כענף נפרד. הענפים מתאחדים בצמתים (nodes) על בסיס המרחק או החוסר דמיון ביניהם. ככל שהצמתים נמצאים גבוה יותר בעץ, כך המרחק או חוסר הדמיון בין הנתונים המשוויכים אליהם גדול יותר. בסופו של דבר, כל הענפים מתאחדים בשורש העץ. באמצעות ניתוח של ה-Dendrogram, ניתן לזהות קבוצות או אשכולות של נכסים דומים על בסיס רמת האיחוד שלהם בעץ. למשל, אם קבוצה של נכסים מתאחדת בצומת נמוכה, סימן שהם דומים זה לזה יותר ממרחק מסוים. זיהוי אשכולות אלו עשוי לחשוף דפוסים ומגמות בשוק הנדל"ן, כולל השפעות אפשריות של גורם

הזמן על קבוצות שונות של נכסים. בנוסף, ניתן לבחון את המרחק בין הענפים השונים ב-Dendrogram כדי להעריך את מידת הדמיון או השוני בין נכסים ספציפיים או קבוצות של נכסים.


הסיבות המרכזיות לבחירת השילוב הנ"ל של שיטות היא השגת פרספקטיבה רחבה על הנתונים, למידת קשרים מורכבים והתגברות על חולשות של כל אלגוריתם בודד. ההנחה הייתה שהשילוב יספק תובנות מעמיקות ומקיפות יותר משהייתה מספקת שיטה בודדת. בכל שלב, היינו צריכים לשקול את הטרייד-אופים של כל גישה - יכולת פענוח הקשרים, מורכבות חישובית וזמן ריצה, וכו'. החשיבה האנליטית שהובילה אותנו הייתה לנסות לאזן בין היתרונות והחולשות תוך ניצול המאפיינים החזקים של כל טכניקה ובחירת הפרמטרים הנכונים.

סעיף 5 – ניסויים/תוצאות/דין:

בחירת פרמטרים:

בפרויקט שלנו, השתמשנו במספר פרמטרים מרכזיים לאופטימיזציה והערכה של אלגוריתמי ה-Clustering שלנו. הפרמטרים נבחרו בהתאם לאלגוריתמי ה-Clustering השונים:



1. **בחירת פרמטר K עבור אלגוריתם K-means** - בחרנו בפרמטר k (מספר הקבוצות) באמצעות שיטת המרפק (Method Elbow), שזיהתה את המספר האופטימלי של קבוצות על פי הנתונים שלנו. לבחירה נכונה של k יש השפעה עצומה על איכות ה-Clustering - ערך נמוך מדי יכול להוביל לאיחוד יתר של קבוצות בעלות תכונות שונות, בעוד שערך גבוה מדי יכול להוביל לפיצול יתר של קבוצות דומות. לפי ניתוח ויזואלי מצאנו לנכון שהאשר עשויים להתאים הם 4/5/6. לאחר בדיקה של כל אחת מהן עם מטריקת הערכה 'Silhouette Score' והחלטנו לפי scoren שהוא הציון הכי גבוה (נע בין מינוס 1 ל-1) שהא כי מתאים הוא $4=K$.




2. **בחירת מרחק מינימלי (אפסילון) ומספר מינימלי של נקודות בכל אשכול (MinPts) עבור אלגוריתם DBSCAN**: מאחר והדאטה שלנו מכילה מעל 40,000 שורות של נתונים (נקודות) יהיה יותר שימושי להתחיל עם MinPts שנע בין 10-20, אנחנו בחרנו להשתמש ב-15. כלומר, שבכל אשכול יהיה מינימום של 15 דגימות/נקודות. המטרה היא להפחית את הסיכוי לזיהוי Cluster'ים קטנים מדי או לסווגם כ'רעש'. נרצה להגדיר הבחירה בפרמטרים אלו השפיעה על היכולת לזהות Cluster'ים בעלי צפיפות גבוהה תוך התעלמות מ'רעש'.

2	10612
4	9964
0	8174
-1	6178
1	4675
5	236
7	217
3	190
8	27
6	9
Name: Cluster,	

עבור בחירת האפסילון התהליך הוא יותר מורכב, תחילה השתמשנו במטריקת הערכה מסוג k-NN (Nearest Neighbors) למציאת ערך סביר. אבל קיבלנו אפסילון ממוצע של 148.41, ערך מאוד גדול ולא מתאים לפרמטר וכתוצאה מכך המודל סיווג לאשכול אחד את כל הדאטה. לכן המשכנו בניסוי וטעייה ובחרנו באפסילון = 0.5.



בחירת פרמטר ה'גובה' עבור אלגוריתם Hierarchical Clustering: פרמטר ה'גובה' היה מרכזי בבחירתו מאחר והוא משפיע על איך לאחד קלאסטרים באופן היררכי.



לפי הדנדוגרמה בתמונה, ניתן לראות שהבחירה נעה בין גובה של 130-150. בטווח גובה זה ניתן לראות הפרדה ברורה לשלושה אשכולות עיקריים, עם אשכול אחד גדול ושני אשכולות קטנים יותר. גובה של כ-130 יחלק את הנתונים לשלושה אשכולות: אשכול אחד גדול עם 6 רכיבים, ואשכולות קטנים יחסית עם 3 ו-2 רכיבים. לעומת זאת בחירת גובה של כ-150 יאחד את שני האשכולות הקטנים לאשכול אחד בעל 5 רכיבים, ויותר את האשכול הגדול בעל 6 הרכיבים. לכן, בחירת גובה בטווח 130-150 תאפשר חלוקה לאשכולות בעלי גודל סביר. אנו בחרנו בגובה של 140.

שימוש במטריקות הערכה השתמשנו במספר מטריקות להערכת איכות Clusters:

- **שימוש במטריקת הערכה מסוג Silhouette Score עבור בחירת K באלגוריתם Means-K:** מדד זה מועיל במיוחד עבור Clustering, כיוון שהוא מודד את מידת הדימיון בין האובייקטים בתוך Cluster לבין אלה ש-Clusters אחרים, ובכך מעריך את איכות ההפרדה בין Clusters. כך הצלחנו להבין באיזה K הכי נכון לנו להשתמש כדי לקבל תוצאה איכותית וטובה יותר עבור האלגוריתם. היכולת לבצע השוואה בין 3 סוגי K שונים אשר היו עשויים להתאים קריטית וחשובה לבניית האלגוריתם K-Means שמשפיע ישירות על התפלגות הנתונים והיכולת לנתח תובנות על הקשרים בין הפיצורים השונים.
- **שימוש במטריקת הערכה מסוג Silhouette Score עבור הערכת טיב האלגוריתמים –**
מטריקה זו מודדת את מידת השיוך של כל נקודת נתונים לאשכול אליו היא משויכת, ביחס לאשכול הקרוב ביותר אליה. Silhouette Score מחושב עבור כל נקודה על ידי הפחתת הממוצע של המרחקים שלה מכל נקודות האשכול השני הקרוב ביותר, מהממוצע של המרחקים שלה מנקודות האשכול שלה עצמה. הממוצע של כל ערכי Silhouette Score במדגם נותן מדד כללי לטיב האשכול - ככל שהערך גבוה יותר, כך האשכולות טובים יותר.
ערכי Silhouette Score נעים בין 1 ל-1:
 - ערכים קרובים ל-1 מצביעים על נקודה טובה באשכול ששויכה אליו, וקבוצות אשכולים טובות.
 - ערכים קרובים ל-0 מרמזים על נקודות שקשה לשייך אותן לאשכול.
 - ערכים שליליים מצביעים על נקודות שמשויכות באופן שגוי לאשכול.
- **שימוש במטריקת הערכה מסוג Davies-Bouldin Index עבור הערכת טיב האלגוריתמים –**
מדד זה מודד את הקומפקטיות והקירבה של כל אשכול ביחס לאשכול הקרוב ביותר אליו. הוא עובד על ידי חישוב הממוצע של הצפיפויות של כל אשכול (להבנת הקומפקטיות) ואז מחלק את הסכום של המרחקים בין מרכזי האשכולות בערך זה. ערכים נמוכים של מדד Davies-Bouldin מצביעים על אשכולות קומפקטיים וברורים. ערכים גבוהים מרמזים על אשכולות "רפויים" שחופפים או קרובים מדי זה לזה. בניגוד ל Silhouette שמתמקד בשיוך של נקודות בודדות Davies-Bouldin, בודק את הצפיפות והקירבה של האשכולות כמכלול. ככל שהערך נמוך יותר, האשכולות נחשבים טובים יותר. המטריקות הללו מצליחות לתת ערך כמותי לטיב האלגוריתם על ידי מדידה של מספר היבטים חשובים באשכולות:
אלגוריתם clustering טוב יקבל ערכי סילואט גבוהים (קרוב ל-1) ו DBI-נמוכים, מכיוון שהוא מצליח ליצור אשכולות צפופים, ברורים ונפרדים זה מזה היטב, ומשייך את הנקודות באופן הולם.
- **שימוש במטריקת הערכה מסוג F1 Score ודיוק עבור בחירת פיצורים:** F1 Score מאזן בין הדיוק והרגישות ומספק מדד כללי יותר לאיכות. השימוש במטריקה זו עזר לנו להבחין בין הפיצורים המורכבים ולהבין למי יש יותר השפעה ומשקל על המחיר של דירה. למעשה, הצגת המשקל/החשיבות של כל פיצור משפיע על התובנות ויכולות הניתוח של תוצאות האלגוריתמים שאנחנו בוחנים.

תוצאות כמותיות:

1. תוצאות המטריקה Silhouette Score עבור האלגוריתמים שנבדקו:

○ 0.5532 - K-Means

○ 0.4875 - DBSCAN

○ 0.3375 - Hierarchical Clustering

2. תוצאות המטריקה Davies-Bouldin Index עבור האלגוריתמים שנבדקו:

○ 0.5497 - K-Means

○ 2.7431 - DBSCAN

○ 0.8557 - Hierarchical Clustering

תוצאות איכותיות:

○ K-Means – יצרנו 6 גרפים המציגים איך הפיצ'רים המשמעותיים משפיעים על המחיר ועל פיהם איך ה Cluster ים מתחלקים. עם זאת, לא הצלחנו להגיע לתובנה או מסקנה משמעותית. הגרפים הציגו איך נקודות הנתונים מתקבצות סביב המרכזים של Cluster ים באופן המשקף את ההפרדה הלוגית של תכונות שונות בנתונים.

הצלחות ומגבלות: ההצלחה ברורה ביכולת לזהות מבנים כלליים בנתונים. המגבלה המרכזית היא הנחת היסוד שכל Cluster ים כדוריים ובגודל דומה, שלא תמיד מתאימה למציאות.

○ DBSCAN – יצרנו 6 גרפים המציגים איך הפיצ'רים המשמעותיים משפיעים על המחיר ועל פיהם איך ה Cluster ים מתחלקים. עם זאת, לא הצלחנו להגיע לתובנה או מסקנה משמעותית. המסקנה העיקרית שהוויזואליזציות הדגימו את היכולת לגלות דפוסים מורכבים ומגוונים בנתונים שלא תמיד נתפסים בשיטות אחרות.

הצלחות ומגבלות: הצליח באיתור Cluster ים בעלי צורות ייחודיות אך התמודד עם אתגר בבחירת הפרמטרים האופטימליים אשר דורשים ניסוי וטעייה.

○ Hierarchical Clustering – יצרנו 6 גרפים המציגים איך הפיצ'רים המשמעותיים משפיעים על המחיר ועל פיהם איך ה Cluster ים מתחלקים. עם זאת, לא הצלחנו להגיע לתובנה או מסקנה משמעותית. המסקנה העיקרית מהוויזואליזציה של Clustering היררכי שהיא מספקת תמונה ברורה על כיצד נקודות נתונים מתקרבות ומתאחדות לקבוצות גדולות יותר, המשקפות את ההיררכיה של הדמיון ביניהן.

הצלחות ומגבלות: Clustering היררכי מציג גמישות גבוהה באפשרות לחקור את הנתונים ברמות שונות. עם זאת, סיבוכיותו החישובית הופכת אותו לפחות מעשי לערכות נתונים גדולות מאוד.

תוצאות בלתי צפויות: הגילוי של Cluster ים או דפוסים לא צפויים בנתונים, כמו קבוצות נכסים ייחודיות בשכונות מסוימות, הדגיש ערוצים חדשים למחקר עתידי. לדוגמה, השונות ב-'מחיר למ"ר' בין Cluster ים שונים עשוי לרמז על גורמים המשפיעים על מחירי הנכסים מעבר לברור מאליו. בנוסף, הדגיש את הצורך בהעמקת האנליזה באמצעות החלת שיטות מתקדמות יותר של למידת מכונה.

ביצועי האלגוריתם:

- יעילות: היעילות של האלגוריתמים השתנתה. K-means הוצג בגלל יעילותו החישובית עבור ערכות נתונים בינוניות עד גדולות, אף על פי שהוא דרש הגדרה מראש של מספר ה-Cluster. DBSCAN הצטיין בזיהוי חריגים ובטיפול ב-Clusters בצורות משתנות ללא צורך בהגדרת מספר ה-Clusters מראש, אך הביצוע שלו היה תלוי בחומרה בבחירת הפרמטרים.
- דיוק התוצאות: ההתאמה של כל אלגוריתם הייתה תלויה במאפייני הערכת הנתונים. יכולת DBSCAN לנהל רעש ולזהות Clusters בצורות שונות הפכה אותו ליעיל במיוחד עבור סט נתונים עם הבדלי צפיפות ברורים. K-means סיפק תוצאות מדויקות ויעילות עבור נתונים עם קבוצות מופרדות היטב ובעלות צורה כדורית.
- התמודדות עם רעש ונקודות חריגות: השיטה שבה פועל DBSCAN מנהלת באופן טבעי רעש ונקודות חריגות, כאשר הוא מזהה אותם כנקודות שאינן שייכות ל-Cluster כלשהו. זה שימושי במיוחד כאשר רוצים לזהות נקודות שמתנהגות שונה מרוב הנתונים. לעומת זאת, K-means עלול להיות מושפע מנקודות חריגות בחישוב המרכזים, Hierarchical Clustering עלול לאפשר לנקודות חריגות לשנות באופן משמעותי את מבנה ה-Clusters.

היה לנו קשה ויזואלית להעריך את ביצועי האלגוריתמים השונים, אך, בעזרת השימוש במטריקות Silhouette Score ו-Davies-Bouldin Index (DBI) יכלנו לבצע השוואה ביניהם. אלגוריתם K-Means היה בעל ציון סילואט הגבוהה ביותר ובעל הציון הנמוך ביותר ב-DBI מה שמעיד על כך שהוא האלגוריתם המתאים יותר.

באשר לניחוש המושכל עבור למה אלגוריתם מסוים יהיה יעיל יותר על פני האחרים, בחרנו באלגוריתם K-means כאלגוריתם היעיל ביותר לניתוח נתוני נדל"ן במסגרת הפרויקט שלנו. הסיבה לכך טמונה בבסיס מספר גורמים קריטיים הקשורים למאפייני הנתונים ולפיצ'רים שבחרנו להשתמש בהם - הניחוש ינומק מהסיבות הבאות:

1. **ליניאריות ודפוסים פשוטים**: הפיצ'רים שבחרנו, כמו 'Price_per_sqm', 'Size_per_room', וכו', נראים כאלו שניתן לתארם ולהבין את התפלגותם בצורה ליניארית יחסית ועם דפוסים לא מורכבים מדי. K-means בעל יתרון משמעותי בקלסטרזציה של נתונים שמתאימים למבנה כזה, שכן הוא מנסה למצוא את מרכז הכובד של כל Cluster ולארגן את הנתונים סביבו, מה שהופך אותו ליעיל כאשר הנתונים מתאימים למודל זה.

2. **יתרונות K-Means בקלסטרזציה פשוטה**: K-Means עדיף על DBSCAN וטוב יותר עבור פיצ'רים ליניאריים כיוון שהוא לא דורש צורות Cluster מוגדרות מראש ומסווג פחות נקודות כרעש, להבדיל מ-DBSCAN שנוטה לסווג נקודות רבות כרעש ולקבל Silhouette Score שלילי. לעומת זאת K-Means מסתמך על מרחקים יחסית ברורים ולכן יכול להתמודד טוב יותר עם הפיצ'רים הנבחרים.

3. **פשטות ויעילות חישובית**: K-Means ידוע בפשטותו וביעילותו החישובית, מה שהופך אותו למתאים במיוחד עבור ניתוח ראשוני של ערכות נתונים גדולות. במקרה של נתוני נדל"ן, שבהם ייתכנו מגוון רחב של ערכים בפיצ'רים מסוימים, היכולת לקבוצ נתונים באופן מהיר ויעיל היא יתרון גדול. לעומת זאת, הסיבוכיות החישובית של Hierarchical Clustering הפכה אותו לפחות מתאים לסט נתונים גדול מאוד כמו במקרה שלנו.

סעיף 6: מסקנות ועבודה עתידית

מסקנות ותרומות

1. **הבנה עמוקה של השוק:** הפרויקט סיפק הבנה עמוקה ומפורטת של שוק הנדל"ן לשכירות, כולל איתור דפוסים כמו אזורים בעלי ביקוש גבוה, טווחי מחירים ותכונות נדל"ן פופולריות.
2. **יישום שיטות Clustering:** הפרויקט משתמש ביישום שלוש שיטות Clustering - K-means, DBSCAN, Hierarchical Clustering - על נתוני נדל"ן, מה שמדגים את היתרונות והאתגרים של כל שיטה.
3. **תובנות לגורמי השוק:** הפרויקט גילה תובנות חשובות לגורמים בשוק הנדל"ן, ויכול לסייע לבעלי עניין שונים כגון סוכני נדל"ן ומשקיעים, המחפשים להבין את הדינמיקה של השוק ולזהות הזדמנויות פוטנציאליות.

חשיבות הפרויקט והשלכותיו

הפרויקט מציע כלים להבנת המגמות והאתגרים בשוק. היכולת לזהות ולנתח דפוסים מאפשרת לגורמים בשוק לקבל החלטות מושכלות בתחום הנדל"ן. כמו כן, הפרויקט מצביע על הפוטנציאל של שימוש בנתונים גדולים ובינה מלאכותית לחיזוי ולהבנת מגמות עתידיות בתחום.

כיוונים עתידיים

1. **ניתוח בזמן אמת:** פיתוח מערכת שתנתח נתונים בזמן אמת ותספק תובנות עדכניות למשתמשים, מה שיאפשר התייחסות מיידי לשינויים בשוק.
2. **העמקת האנליזה באמצעות שימוש בלמידת מכונה:** החלת שיטות מתקדמות יותר של למידת מכונה ובינה מלאכותית כדי לחזות מגמות בשוק ולזהות מגמות עתידיות. זה יכול לכלול פיתוח מודלים לחיזוי מחירי שכירות או לזיהוי השפעות של פרמטרים חברתיים-כלכליים על שוק הנדל"ן.
3. **אינטגרציה של נתונים גיאוגרפיים:** שילוב של מידע גיאוגרפי ומפות תרמיות להבנה עמוקה יותר של ההשפעה המרחבית על מאפייני הנדל"ן. זה יכול לעזור באיתור אזורים 'חמים' בשוק או בזיהוי אזורים בעלי פוטנציאל צמיחה.
4. **התייחסות להיבטים סביבתיים וחברתיים בהקשרי מרחק:** חקירת השפעות של גורמים סביבתיים וחברתיים על שוק הנדל"ן, כגון הקרבה לפארקים, בתי ספר, מרכזים קהילתיים, קרבה לחוף הים, תחנות רכבת וכו' והשפעתם על ערך הנכסים.
5. **התייחסות להערכת שמאות:** גילום של גורם מקצועי אשר משפיע על קביעת ערך הנכס וכתוצאה מכך על קביעת השכירות.
6. **חקר האפקט של טכנולוגיות חדשות:** בדיקת השפעת טכנולוגיות חדשות, כגון בית חכם ופתרונות ירוקים, על שוק הנדל"ן. האם דירות עם טכנולוגיות אלה נתפסות כיותר מבוקשות? איזה טכנולוגיות מושכות את השוכרים?
7. **אופטימיזציה וכוונון:** התהליך של כווןן האלגוריתמים והפרמטרים דורש זמן ונסיון, וכלול בו ניסוי וטעייה. השקעה באופטימיזציה זו יכולה להביא לשיפור משמעותי באיכות Clustering ובמיצוי התובנות מהנתונים.

לקחים שנלמדו ושאלות חדשות

הפרויקט הזה הדגיש את החשיבות של ניתוח נתונים מדויק ומעמיק בהבנת שוק הנדל"ן. אחת ההנחות המרכזיות היא שהנתונים תמיד משתנים ודורשים ניתוח רציף כדי להישאר עדכניים למול המגמות החדשות. השימוש במגוון שיטות Clustering הוביל לשאלות חדשות, כמו:

- האם שיטת Clustering מתאימה וחזקה מספיק לסיווג וניתוח נתוני נדל"ן על פני שיטות אחרות? או שכדאי לשלב שיטות נוספות?
- האם ישנם גורמים נוספים שלא נלקחו בחשבון עד כה, המשפיעים על החלוקה ל-Clusters?
- האם ואיך ניתן לשפר את הדיוק של האלגוריתמים על ידי שילוב נתונים נוספים כמו נתונים דמוגרפיים או כלכליים?
- מהם ההשפעה של שינויים פוליטיים או כלכליים על ערכי הנדל"ן באזורים שונים?

סעיף 7: חלוקת עבודת הצוות

הפרויקט בוצע על ידי צוות המורכב משני חברי צוות – סהר ועמית. עמית מתעניין במשך שנים בעולמות הנדל"ן והציע שנבצע את הפרויקט בתחום שכריות הנדל"ן. ביחד חשבנו על המטרה שבגינה אנחנו מעוניינים לבצע את הפרויקט, מה האולגרייתמים והמטריקות שאנחנו מעוניינים להשתמש ומה המוטיבציה שלנו לכל זה. במרבית ביצוע העבודה, עבדנו באופן משולב החל ממשיכת הדאטה, בחינת האלגוריתמים, הסקת מסקנות, ניתוח תוצאות ועד לכתיבת הדו"ח. באופן טבעי, העבודה התחלקה כך שאחד מחברי הצוות היה אחראי על חלק אחר מהפרויקט. על כתיבת הקוד המרכזי של הפרויקט (עמית) וחבר הצוות השני היה אחראי על כתיבת הדו"ח המסכם של הפרויקט (סהר). חשוב להדגיש, שני החלקים בוצעו בשיתוף פעולה מלא ועבודה משותפת בכל חלק וחלק, הדגש הוא על מי שמוביל כל חלק. כך התרומה באה לידי ביטוי בצורה איכותית ויעילה יותר. מי שכותב את הקוד שומר על המקצועיות והכרת הקוד והניואנסים בצורה מקסימלית אך אין זה פוגע בחבר הצוות השני אשר מעורב בכל שלב ושלב. בהתאמה בכתיבת הדו"ח, כתיבת הדו"ח על ידי אדם אחד מובילה לניסוח אחיד וכתיבת דו"ח באופן עקבי. לצד זה, כדי להצליח לכתוב את הדו"ח בצורה מיטבית שיתוף הפעולה קריטי - דיונים בני חברי הצוות, תרגום הנתונים מכתיבת הקוד לדו"ח, הסברת התוצאות והמסקנות על ידי שיח משותף היו מקור להצלחת כתיבת הדו"ח.

קישור ל-GITHUB של הפרויקט